

Auditoria da completude temporal dos dados abertos de arrecadação federal por UF com Python

Giovanni Brígido

Receita Federal do Brasil — Auditor-Fiscal

E-mail: a informar pelo autor

Resumo

Este estudo avalia a completude de dados públicos de arrecadação federal, distinguindo lacunas de preenchimento de ausências previstas no dicionário de dados. A prova de conceito aplica controles em Python à publicação por unidade da Federação, no período de 2000 a 2025. O recorte contém 8.424 registros e cobre 312 meses nas 27 unidades federativas. Nove colunas relativas à Cofins, ao PIS/Pasep e à CSLL foram avaliadas por intervalos de publicação documentados. A contagem indiscriminada identificou 29.160 campos vazios; todos estavam fora dos intervalos de aplicabilidade definidos. A completude passou de 61,54% na medida indiscriminada para 100,00% na medida condicionada. O resultado evidencia a importância dos metadados na triagem de qualidade, sem certificar a exatidão dos montantes arrecadados. O produto é um procedimento reproduzível de apoio à governança da informação, acompanhado de regras, registros de execução e testes controlados.

Palavras-chave: qualidade de dados; arrecadação federal; completude; governança; Python.

1 Contextualização e descrição do problema

A Receita Federal publica uma série de arrecadação mensal por unidade da Federação, com valores em reais e categorias de receitas administradas e não administradas pelo órgão ([Receita Federal do Brasil, s.d.a](#); [Receita Federal do Brasil, s.d.b](#)). No contexto de uso desses dados por um auditor, o problema aqui delimitado é avaliar se a série aberta oferece cobertura adequada para análises e relatórios. Trata-se de uma oportunidade de controle da informação, cuja relevância decorre da necessidade de examinar completude e adequação dos dados antes de utilizá-los como evidência ([U.S. Government Accountability Office, 2019](#)).

O dicionário registra mudanças na estrutura de publicação. Cofins, PIS/Pasep e CSLL aparecem em colunas agregadas até dezembro de 2003 e em categorias “Financeiras” e “Demais” a partir de janeiro de 2004 ([Receita Federal do Brasil, s.d.b](#)). Assim, a ausência de um valor pode decorrer da estrutura histórica do arquivo. A questão de pesquisa é: *como incorporar os intervalos documentados de publicação para evitar que ausências previstas sejam indevidamente encaminhadas como falhas de completude?*

A proposta busca reduzir revisões desnecessárias e preservar o significado dos campos, coerentemente com a compreensão de que qualidade depende do contexto de uso (WANG; STRONG, 1996). Não se afirma que a Receita utilize hoje uma validação indiscriminada: essa abordagem foi construída como referência de comparação. Tampouco o estudo identifica contribuintes, estima sonegação ou atribui desempenho a unidades administrativas.

2 Fundamentação e técnica selecionada

A técnica escolhida é a verificação de qualidade por regras determinísticas, com cruzamento entre observações e metadados temporais. A literatura distingue qualidade de mera precisão e reconhece dimensões contextuais e de representação (WANG; STRONG, 1996). A orientação do GAO também relaciona a confiabilidade dos dados à finalidade da auditoria (U.S. Government Accountability Office, 2019). Neste estudo, operacionaliza-se a completude como preenchimento das células para as quais o dicionário prevê a publicação da categoria correspondente.

Seja $A_{ij} = 1$ quando a coluna j é aplicável ao mês do registro i , e $P_{ij} = 1$ quando existe conteúdo não vazio. As duas medidas são:

$$C_{\text{simples}} = \frac{\sum_{i,j} P_{ij}}{N}, \quad C_{\text{temporal}} = \frac{\sum_{i,j} A_{ij} P_{ij}}{\sum_{i,j} A_{ij}}.$$

O denominador N corresponde às células das nove colunas no recorte. O conteúdo “0” conta como preenchido. A validade numérica é examinada separadamente. Presença fora do intervalo gera uma ocorrência própria, pois pode indicar mudança do arquivo ou desatualização do dicionário.

A abordagem é apropriada porque cada decisão pode ser explicada por uma regra e uma data verificáveis. Um modelo de linguagem acrescentaria incerteza à aplicação de intervalos já explícitos. O registro das regras e dos indicadores adota o princípio de explicitar as métricas e sua proveniência, discutido pelo W3C (World Wide Web Consortium, 2016); não houve implementação do vocabulário RDF dessa organização.

3 Metodologia e dados

Foram baixados diretamente do repositório oficial o CSV e seu dicionário em PDF, com preservação dos arquivos originais, endereços, horário UTC e hashes SHA-256. A análise utiliza janeiro de 2000 a dezembro de 2025, mantendo um intervalo de anos completos. O arquivo adquirido também contém meses de 2026, que ficaram fora do recorte. A rotina verifica os hashes antes de analisar e reutiliza a cópia congelada em execuções posteriores.

O fluxo em Python compreendeu: aquisição com `requests`; leitura como texto com `pandas`, separador ponto e vírgula e codificação Latin-1; validação de datas, UFs e chave composta ano–mês–UF; comparação com o produto cartesiano de meses e 27 UFs; validação lexical das colunas de valores; cruzamento das nove colunas com regras em JSON; e exportação de tabelas e figura com `matplotlib`. O dicionário é a fonte dos intervalos, transcritos antes da

comparação com os campos vazios ([Receita Federal do Brasil, s.d.b](#)).

Cada célula do recorte recebeu um de quatro estados: preenchida e aplicável; ausente e aplicável; ausente fora do intervalo; ou preenchida fora do intervalo. Os dois estados que divergem da expectativa documental são encaminhados para revisão. As demais 33 colunas de valores receberam apenas a checagem lexical; sua completude temporal não foi avaliada. Não houve soma indiscriminada de categorias nem preenchimento automático de vazios com zero.

O arquivo apresenta diferentes convenções de separadores numéricos. O controle reconhece sintaxes com vírgula ou ponto como separador decimal e agrupamentos de milhar compatíveis, mas preserva o texto original. Uma representação ambígua não é convertida automaticamente. Consequentemente, o estudo verifica presença e formato, sem recalcular valores ou certificar sua exatidão.

A validação funcional introduziu defeitos isolados em cópias da base: ausência aplicável, presença fora do intervalo, texto não numérico, mês ou UF inválidos, duplicação e remoção de registro. Casos de controle verificaram zero, sinal negativo, separadores e os meses adjacentes à mudança de 2004. Os resultados foram comparados com as classes esperadas. Esse procedimento testa a implementação e não estima precisão ou revocação em falhas reais, que exigiriam avaliação independente.

Os arquivos analisados são agregados por UF e mês, sem identificadores de pessoas ou empresas. O processamento não consulta bases sigilosas nem transmite dados a serviços de IA. Uma adoção institucional dependeria da validação das regras pelo responsável pela publicação e da atribuição de responsabilidades para manter metadados e tratar ocorrências, em linha com a participação dos envolvidos na avaliação de confiabilidade ([U.S. Government Accountability Office, 2019](#)).

4 Resultados e impacto na governança

O recorte apresentou 8.424 registros, equivalentes a 312 meses vezes 27 UFs, sem chaves duplicadas ou ausentes. Não foram detectados meses ou UFs inválidos nem representações numéricas fora das sintaxes aceitas. Para as nove colunas, foram classificadas 75.816 células, das quais 46.656 pertenciam aos intervalos documentados.

Tabela 1: Completude das nove colunas no período de 2000–2025.

Indicador	Resultado
Células avaliadas	75.816
Células aplicáveis	46.656
Vazios identificados sem regra temporal	29.160
Ausências dentro do intervalo aplicável	0
Completude sem regra temporal	61,54%
Completude condicionada ao intervalo	100,00%

Todas as 29.160 ausências foram classificadas como previstas, sem presenças fora do intervalo. A mudança entre as medidas resulta da alteração do denominador, e não de correção da

base. A figura mostra como a multiplicação das categorias publicadas em 2004 altera a contagem simples. A completude condicionada permanece em 100% nas nove colunas, resultado restrito à definição adotada e à versão do arquivo.




Figura 1: Comparação anual das medidas nas nove colunas selecionadas.

Os 13 cenários controlados passaram pelos critérios esperados. O produto operacional é uma tabela de ocorrências com chave, coluna, regra e valor original, acompanhada da classificação de todas as células do recorte. Na base observada, a tabela ficou sem ocorrências segundo os controles definidos. Um uso possível é verificar novas versões antes de incorporá-las a relatórios e encaminhar divergências ao responsável pelos dados.

Os ganhos de tempo e de redução de retrabalho permanecem potenciais, pois não foram medidos com usuários. O estudo não compara a arrecadação publicada com documentos de origem e não avalia pontualidade das divulgações. Regras desatualizadas podem produzir alertas indevidos; valores incorretos, mas preenchidos e sintaticamente válidos, podem passar despercebidos. Uma métrica favorável em um aspecto não resolve a avaliação de adequação global dos dados (WANG; STRONG, 1996; World Wide Web Consortium, 2016).

5 Considerações finais

A prova de conceito demonstrou que metadados temporais modificam substancialmente a interpretação da completude no recorte estudado. Sua contribuição é um controle simples, explicável e reproduzível para a governança dos dados públicos de arrecadação. Os resultados permitem separar ausências documentadas de exceções que requerem investigação, sem transformar completude em garantia de exatidão. Como próximos passos, propõe-se validar as regras com o responsável pela base, ampliar a cobertura temporal das demais categorias e testar o procedimento em novas versões, preservando histórico de mudanças e medindo o esforço de revisão.

Referências

Receita Federal do Brasil. *Arrecadação por estado*. s.d. Disponível em: <<https://www.gov.br/receitafederal/dados/arrecadacao-estado.csv/view>>. Acesso em: 5 set. 2026.

Receita Federal do Brasil. *Arrecadação por UF: dicionário de dados*. s.d. Disponível em: <<https://www.gov.br/receitafederal/dados/arrecadacao-estado-metadados.pdf>>. Acesso em: 5 set. 2026.

U.S. Government Accountability Office. *Assessing Data Reliability*. Washington, DC, 2019. GAO-20-283G. Disponível em: <<https://www.gao.gov/products/gao-20-283g>>. Acesso em: 5 set. 2026.

WANG, R. Y.; STRONG, D. M. Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, v. 12, n. 4, p. 5–33, 1996. DOI: [10.1080/07421222.1996.11518099](https://doi.org/10.1080/07421222.1996.11518099).

World Wide Web Consortium. *Data on the Web Best Practices: Data Quality Vocabulary*. [S.l.], 2016. Working Group Note, 15 dez. 2016. Disponível em: <<https://www.w3.org/TR/vocab-dqv/>>. Acesso em: 5 set. 2026.