

Proposta de recuperação aumentada por geração para análise auditável de discursos do Senado Federal

Fabricio Fernandes Santana

Coordenador de Informática Legislativa e Parlamentar

Prodasen - Senado Federal

E-mail: fabricio.santana@gmail.com

Resumo

Este artigo propõe uma solução de recuperação aumentada por geração (*retrieval-augmented generation*, RAG) para apoiar a consulta auditável a pronunciamentos do Senado Federal. O desenho da solução combina recuperação de informação, geração condicionada às evidências e apresentação dos metadados das fontes. Busca-se localizar e sintetizar manifestações sem substituir a análise humana nem atribuir ao modelo a verificação autônoma de fatos ou de conformidade. O corpus reúne discursos da 56ª Legislatura obtidos de fonte pública e estruturados no Hugging Face. Avaliaram-se a qualidade dos dados e a recuperação; a fidelidade das respostas integra etapa futura. O trabalho apresenta um fluxo experimental reproduzível, com registro das evidências e salvaguardas previstas contra respostas sem fundamento.

Palavras-chave: accountability; discursos parlamentares; recuperação de informação; RAG; inteligência artificial generativa.

1 Contextualização e descrição do problema

O Senado Federal disponibiliza dados de pronunciamentos parlamentares em seu portal de dados abertos ([Senado Federal, s.d.](#)). Embora a publicidade dos registros seja indispensável, o volume textual e a dispersão dos metadados dificultam a localização e a comparação manual de manifestações relacionadas a um tema, período ou parlamentar. Buscas estritamente lexicais também podem não recuperar documentos semanticamente próximos que empreguem vocabulários diferentes ([MANNING; RAGHAVAN; SCHÜTZE, 2008](#)). No setor público, a incorporação de ciência de dados pode alterar não apenas a produção e a análise de informações, mas também as práticas de transparência e prestação de contas (accountability) ([AGOSTINO et al., 2026](#)). Sem um apoio automatizado, a pesquisa manual eleva o tempo de resposta e o risco de omitir pronunciamentos relevantes.

Nesse contexto, investigou-se a viabilidade de uma solução RAG auditável para apoiar pesquisadores, servidores e instâncias de controle na consulta a pronunciamentos da 56ª Legislatura. A prova de conceito recupera documentos; em sua versão completa, o sistema

deverá sintetizar apenas as evidências disponíveis e apresentar autor, data, partido, unidade da Federação e endereço da fonte. Não se pretende inferir intenção, determinar a veracidade de declarações nem automatizar juízos sobre parlamentares.

2 Fundamentação e técnica selecionada

A arquitetura RAG associa um mecanismo de recuperação documental a um modelo gerador, condicionando a resposta ao contexto selecionado (LEWIS et al., 2020). Em comparação com a consulta manual, a recuperação semântica amplia as formas de expressão aceitas; em comparação com o uso isolado de um modelo de linguagem, a recuperação oferece evidências verificáveis e reduz a dependência do conhecimento paramétrico do modelo (GAO et al., 2023).

A escolha é adequada ao problema porque o objeto de análise é essencialmente textual e já contém metadados úteis à rastreabilidade. Neste trabalho, auditabilidade não significa certificação formal, mas a possibilidade de examinar dados, parâmetros, resultados e evidências por meio de controles técnicos e processuais (MöKANDER, 2023): versionamento do corpus, registro dos parâmetros, citações obrigatórias, possibilidade de abstenção e avaliação separada da recuperação e da geração (SAAD-FALCON et al., 2024).

3 Metodologia e dados

O corpus foi obtido diretamente do conjunto de discursos da 56ª Legislatura, publicado no Hugging Face por Santana (2025). A base contém metadados dos pronunciamentos e o texto integral quando sua coleta foi bem-sucedida. Antes da indexação, foram avaliados esquema, duplicidades, campos ausentes, cobertura textual, datas e consistência dos identificadores. A revisão também distinguiu falha de coleta de inexistência de discurso, evitando interpretar ausência de texto como ausência de atividade parlamentar.

O fluxo implementado compreendeu: (1) download e registro da revisão e do hash do arquivo; (2) validação e normalização com Python e pandas; (3) seleção de texto e metadados; (4) demonstração de segmentação com sobreposição; (5) indexação lexical e vetorial; (6) fusão dos rankings; e (7) armazenamento dos resultados. A segmentação de mil documentos produziu 5.696 trechos; para uma comparação uniforme, a avaliação dos três métodos indexou os 15.039 discursos no nível documental. A geração de respostas e a apresentação automatizada das citações permanecem como extensão futura. Essa separação permite avaliar a recuperação independentemente da resposta gerada (GAO et al., 2023; SAAD-FALCON et al., 2024).

A prova de conceito compara TF-IDF com até 80 mil termos, representações vetoriais (*embeddings*) do modelo `text-embedding-3-large`, com 512 dimensões, e fusão dos rankings por *Reciprocal Rank Fusion* (RRF), método que combina rankings sem exigir comparabilidade entre seus escores (CORMACK; CLARKE; BÜTTCHER, 2009). Foram elaboradas dez perguntas a partir dos resumos oficiais, cada uma associada a um pronunciamento conhecido, enquanto somente os textos integrais formaram os índices. Entradas acima do limite foram truncadas em 8 mil tokens, afetando 104 dos 15.039 documentos. O experimento mede busca de item conhecido

por $\text{Hit}@k$ e *Mean Reciprocal Rank* (MRR), mas não estima *recall* temático, pois outros documentos potencialmente relevantes ainda não foram julgados (MANNING; RAGHAVAN; SCHÜTZE, 2008).

Para ampliar os julgamentos, reuniu-se a união dos dez primeiros resultados de cada método, totalizando 205 pares após deduplicação. Um grande modelo de linguagem (LLM) como juiz, sem acesso ao método ou à posição, atribuiu relevância 0, 1 ou 2 em duas passagens. Divergências, baixa confiança ou evidência insuficiente foram adjudicadas por uma terceira chamada. As duas passagens receberam o resumo e um excerto de até 1.200 caracteres selecionado por termos da pergunta; a adjudicação recebeu até 30 mil caracteres iniciais. Essa estratégia é coerente com propostas de avaliação automatizada de RAG e de controle de consistência do juiz (SAAD-FALCON et al., 2024; LIU et al., 2025). Não houve avaliação humana dos pares; assim, esses rótulos constituem uma aproximação automática de relevância, e não um padrão-ouro (CHEN et al., 2024).

Os dados são públicos, mas seu tratamento deve observar finalidade, necessidade, integridade e segurança. O desenho proposto prevê a manutenção dos textos em seu contexto documental, em conformidade com a Lei de Acesso à Informação (Brasil, 2011) e com os princípios da Lei Geral de Proteção de Dados (Brasil, 2018). Também exclui a produção de perfis ou classificações individuais sem base metodológica e finalidade legítima. O envio dos textos a uma API externa também exige análise de segurança, retenção, minimização e condições contratuais antes de eventual adoção institucional.

4 Resultados e impacto potencial

A auditoria identificou 15.729 pronunciamentos e 15.039 textos integrais disponíveis, correspondentes a 95,61% do corpus. Não foram encontrados identificadores duplicados nem datas inválidas; partido e unidade da Federação estavam ausentes em 2.074 registros. Essa ausência coincide principalmente com autores externos e deve ser distinguida de erro cadastral. O corpus abrange 1º de fevereiro de 2019 a 10 de janeiro de 2023, 1.794 autores e 32 partidos.




Figura 1: Pronunciamentos e disponibilidade de texto integral por mês.

O TF-IDF obteve Hit@1 de 20%, Hit@5 e Hit@10 de 40%, MRR de 0,301 e mediana da posição 17,5. A busca vetorial obteve, respectivamente, 0%, 30%, 40%, 0,112 e 44,5. A fusão híbrida alcançou 10%, 30%, 50%, 0,212 e 11,5. Portanto, o método lexical apresentou o maior MRR, enquanto o híbrido ampliou a cobertura em dez resultados e reduziu a mediana da posição. As representações vetoriais não foram superiores de forma geral, embora tenham beneficiado consultas específicas sobre desinformação e processo legislativo.

O resultado fornece evidência preliminar da viabilidade do fluxo e desaconselha presumir que maior similaridade semântica garante relevância. As perguntas derivadas dos resumos podem favorecer correspondências lexicais; o índice contém apenas o texto integral, e apenas um documento foi rotulado por consulta. Logo, as diferenças não permitem generalização estatística e devem orientar uma avaliação temática com julgamentos mais abrangentes.

Nas duas passagens do juiz, a concordância exata foi 62,9% e o kappa ponderado quadrático foi 0,690; 136 itens exigiram adjudicação. Com os rótulos finais do LLM, o híbrido obteve os maiores valores em quatro das cinco métricas descritivas da Tabela 1.

Tabela 1: Desempenho no pool com julgamento por LLM.

Método	P@5	P@10	R@10 _{pool}	MRR	nDCG@10
TF-IDF	0,84	0,81	0,488	1,00	0,719
OpenAI	0,84	0,82	0,533	0,95	0,690
Híbrido RRF	0,92	0,89	0,566	1,00	0,840

A concordância quantifica a consistência interna, mas não valida os rótulos contra julgamentos independentes (LIU et al., 2025; CHEN et al., 2024). O R@10_{pool} considera apenas os itens relevantes da união avaliada, não a revocação no corpus completo.

Como extensão futura, o protótipo completo deverá responder a questões temáticas com links e metadados que permitam ao usuário conferir cada afirmação. Esta etapa produziu o corpus versionado, o índice de recuperação, o conjunto de perguntas de avaliação, métricas reprodutíveis e registros das evidências recuperadas.

A aplicação pode reduzir o tempo de pesquisa e ampliar a cobertura documental de análises legislativas. Seus resultados devem ser entendidos como subsídio, e não como prova autônoma. Entre as limitações estão discursos sem texto integral, erros nos metadados, perda de contexto pelo truncamento, falhas de recuperação, vieses do corpus e alucinações do modelo gerador. Falsos negativos podem omitir pronunciamentos relevantes, enquanto falsos positivos podem associar trechos apenas superficialmente relacionados à pergunta (JI et al., 2023). Além disso, um juiz baseado em LLM pode reproduzir vieses, interpretar de modo instável a rubrica ou favorecer o método vetorial. A seleção dos excertos pode omitir evidências. Dupla passagem e adjudicação mitigam inconsistências, mas não eliminam esses vieses (CHEN et al., 2024).

5 Considerações finais

A proposta articula transparência legislativa, governança de dados e IA generativa em um fluxo que privilegia a rastreabilidade. O experimento sustenta a viabilidade técnica preliminar

das etapas de aquisição, auditoria e recuperação, apoiadas por dados públicos estruturados e ferramentas maduras para preparação, indexação e avaliação (MANNING; RAGHAVAN; SCHÜTZE, 2008; SAAD-FALCON et al., 2024). Como próximos passos, o conjunto inicial de referência deverá ser ampliado, seguido da avaliação da geração e da definição dos critérios de abstenção. A adoção institucional dependerá ainda de validação com usuários, monitoramento contínuo e definição explícita de responsabilidades sobre as conclusões produzidas.

Referências

- AGOSTINO, D. et al. Data science and public sector accounting: Reviewing impacts on reporting, auditing, and accountability practices. *Public Money & Management*, v. 46, n. 6, p. 690–699, 2026.
- Brasil. *Lei n. 12.527, de 18 de novembro de 2011: Lei de Acesso à Informação*. 2011. Diário Oficial da União, Brasília, DF.
- Brasil. *Lei n. 13.709, de 14 de agosto de 2018: Lei Geral de Proteção de Dados Pessoais*. 2018. Diário Oficial da União, Brasília, DF.
- CHEN, G. H. et al. Humans or llms as the judge? a study on judgement bias. In: *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Miami: Association for Computational Linguistics, 2024. p. 8301–8327.
- CORMACK, G. V.; CLARKE, C. L. A.; BÜTTCHER, S. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In: *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*. New York: ACM, 2009. p. 758–759.
- GAO, Y. et al. Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*, 2023.
- JI, Z. et al. Survey of hallucination in natural language generation. *ACM Computing Surveys*, v. 55, n. 12, p. 1–38, 2023.
- LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in Neural Information Processing Systems*, v. 33, p. 9459–9474, 2020.
- LIU, S. et al. Judge as a judge: Improving the evaluation of retrieval-augmented generation through the judge-consistency of large language models. In: *Findings of the Association for Computational Linguistics: ACL 2025*. Vienna: Association for Computational Linguistics, 2025. p. 5788–5807.
- MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. *Introduction to Information Retrieval*. Cambridge: Cambridge University Press, 2008. Disponível em: <<https://nlp.stanford.edu/IR-book/>>. Acesso em: 4 set. 2026.
- MöKANDER, J. Auditing of ai: Legal, ethical and technical approaches. *Digital Society*, v. 2, n. 3, p. 49, 2023.
- SAAD-FALCON, J. et al. Ares: An automated evaluation framework for retrieval-augmented generation systems. In: *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Mexico City: Association for Computational Linguistics, 2024. p. 338–354.
- SANTANA, F. *Discursos do Senado Federal: 56ª Legislatura*. Hugging Face Datasets, 2025. Disponível em: <<https://huggingface.co/datasets/fabriciosantana/discursos-senado-legislatura-56>>. Acesso em: 4 set. 2026.

Senado Federal. *Portal de Dados Abertos do Senado Federal*. s.d. Disponível em: <<https://legis.senado.leg.br/dadosabertos/>>. Acesso em: 4 set. 2026.