

Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa
Programa de Pós-Graduação em Administração Pública
Mestrado Profissional

TÉCNICAS DE AVALIAÇÃO DE SISTEMAS RAG :

aplicação empírica a discursos parlamentares do Senado Federal

FABRICIO FERNANDES SANTANA

Brasília/DF
Maio/2026

FABRICIO FERNANDES SANTANA

TÉCNICAS DE AVALIAÇÃO DE SISTEMAS RAG :

aplicação empírica a discursos parlamentares do Senado Federal

Pré-projeto de dissertação apresentado como requisito final para avaliação na disciplina de Projeto de Pesquisa, do Mestrado Profissional em Administração Pública, do Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa (IDP), ministrada pelos Profs. Drs. Hélio Bomfim de Macêdo Filho e Marcelo Rodrigo de Souza Pita.

Brasília/DF
Maio/2026

FABRICIO FERNANDES SANTANA

TÉCNICAS DE AVALIAÇÃO DE SISTEMAS RAG :

aplicação empírica a discursos parlamentares do Senado Federal

BANCA EXAMINADORA:

Prof. Dr. Hélio Bomfim de Macêdo Filho
Projeto de Pesquisa

Prof. Dr. Marcelo Rodrigo de Souza Pita
Projeto de Pesquisa

Sumário

1	Introdução	1
1.1	Contextualização temática	1
1.2	Apresentação da problemática e da pergunta de pesquisa	4
1.3	Enunciação dos objetivos	5
1.3.1	Geral	5
1.3.2	Específicos	6
2	Referencial teórico	6
2.1	Inteligência artificial generativa, RAG e recuperação da informação	6
2.2	Informação legislativa, transparência e acervos parlamentares	7
2.3	Avaliação de sistemas RAG em domínios institucionais	8
2.4	Lacuna de pesquisa	9
3	Hipóteses do estudo	10
4	Metodologia	11
4.1	Natureza e abordagem da pesquisa	11
4.2	Fundamentação empírica: dados e técnicas de coleta	13
4.3	Técnicas de análise dos dados e matriz de opções metodológicas	14
4.4	Recursos, viabilidade e transparência no uso de IA	16
5	Cronograma da pesquisa	19
6	Referências	21

1. INTRODUÇÃO

1.1. Contextualização temática

No campo da inteligência artificial generativa, grandes modelos de linguagem (*large language models* – LLMs) são modelos capazes de produzir texto em linguagem natural a partir de padrões aprendidos em grandes volumes de dados textuais (BROWN et al., 2020; ZHAO et al., 2023; MINAEE et al., 2024). Apesar dessa capacidade, LLMs não garantem, por si só, confiabilidade factual, atualização ou verificabilidade documental, pois, quando utilizados de forma isolada, podem produzir respostas plausíveis sem correspondência documental verificável, refletir limitações de atualização decorrentes de bases usadas no treinamento e deixar de indicar as evidências que sustentam cada afirmação (JI et al., 2023; ANH-HOANG et al., 2025; DAHL et al., 2024).

Para mitigar limitações e riscos associados ao uso isolado de LLMs, foi proposta a abordagem *retrieval-augmented generation* (RAG), que combina modelos generativos com mecanismos de recuperação da informação (LEWIS et al., 2020). Nessa abordagem, em vez de depender apenas do conhecimento paramétrico incorporado ao modelo, a geração da resposta passa a ser condicionada por documentos recuperados de uma base documental externa (LEWIS et al., 2020; GAO et al., 2023).

Entretanto, o uso de RAG não elimina o desafio relacionado à qualidade e à verificabilidade das respostas; esse desafio passa a depender da arquitetura do sistema, especialmente do *pipeline*, que é formado por diversos componentes, tais como: preparação dos dados, segmentação textual ou *chunking*, qualidade dos metadados, modelo de *embedding*, estratégia de recuperação, seleção, filtragem ou reranqueamento de contexto, desenho do *prompt*, modelo gerador e critérios de pós-processamento (GAO et al., 2023; GUPTA et al., 2024; GAO et al., 2024). A Figura 1 apresenta os componentes da arquitetura RAG, cujas configurações podem influenciar, isoladamente ou em conjunto, a qualidade das respostas e das evidências recuperadas.




Figura 1: Componentes de um *pipeline* RAG relevantes para a avaliação de recuperação, geração e verificabilidade

Fonte: elaborado pelo autor. (2026) -- não esquecer da data na indicação da fonte. Revisar demais figuras, tabelas, etc.

A introdução da arquitetura RAG faz com que a avaliação desses sistemas seja um problema multidimensional, uma vez que não basta examinar a fluência da resposta final; é necessário considerar também como diferentes configurações influenciam a qualidade das respostas e das evidências recuperadas (LIANG et al., 2023; SAAD-FALCON et al., 2024; ES et al., 2023; PIPITONE; HOUIR ALAMI, 2024). Isso porque uma resposta fluente pode estar apoiada em evidências frágeis; uma recuperação pertinente pode ser

mal aproveitada pela geração; e uma avaliação automatizada pode superestimar respostas formalmente plausíveis, mas insuficientemente fundamentadas (LIU, Y. et al., 2023; LIU, S. et al., 2025).

Para enfrentar essa multidimensionalidade, a literatura sobre avaliação de RAG, exemplificada por propostas como RAGAS, ARES e LegalBench-RAG, apresenta técnicas de avaliação complementares (ES et al., 2023; SAAD-FALCON et al., 2024; PIPITONE; HOUIR ALAMI, 2024). Essas técnicas incluem: métricas de recuperação (como *recall*, *precision*, **MRR** e **nDCG**), que medem a pertinência dos documentos recuperados (MANNING et al., 2008; THAKUR et al., 2021); rubricas de avaliação de geração, que examinam correteza factual, aderência ao contexto e verificabilidade; avaliação humana de respostas, que captura dimensões qualitativas e contextualmente relevantes; avaliação automatizada baseada no paradigma *LLM-as-a-judge*, que permite ampliar a escala de julgamentos, embora exija controle de consistência e critérios explícitos; e análise qualitativa de erros, que revela padrões e casos críticos (LIU, Y. et al., 2023; LIU, S. et al., 2025).

Esse problema avaliativo é especialmente relevante para organizações da administração pública que operam acervos digitais extensos. Nesses ambientes, respostas produzidas por sistemas generativos não podem ser examinadas apenas por fluência ou utilidade aparente. Elas precisam ser verificáveis, rastreáveis, aderentes às evidências recuperadas e compatíveis com requisitos de transparência, responsabilização e supervisão humana (ALMEIDA; SANTOS JÚNIOR, 2025; WESTMINSTER FOUNDATION FOR DEMOCRACY, 2023; INTER-PARLIAMENTARY UNION, 2024).

No Poder Legislativo, essas exigências assumem contornos próprios. Discursos parlamentares, debates, proposições, pareceres e demais documentos públicos registram posições políticas, justificativas, argumentos técnicos e trajetórias institucionais que interessam a parlamentares, equipes técnicas, pesquisadores, jornalistas, organizações da sociedade civil e cidadãos (GEUNIS, 2023; SKUBIC; FIŠER, 2024). Embora a publicidade desses documentos seja condição necessária para a transparência, ela não garante, por si só, acesso substantivo à informação (BANDEIRA; BERNARDES, 2016). Grandes acervos legislativos combinam volume elevado, diversidade temática, dispersão temporal, variação terminológica, autoria múltipla e dependência de metadados, características que desafiam métodos tradicionais de recuperação da informação e também tensionam sistemas RAG (MANNING et al., 2008; SKUBIC; FIŠER, 2024; MARTELLOTE VIOLA et al., 2025).

No Senado Federal brasileiro, os pronunciamentos em plenário constituem um **corpus** especialmente pertinente para investigar esse problema. Estudos do Núcleo de Estudos e Pesquisas da Consultoria Legislativa indicam que esses registros combinam grande volume documental, variação de extensão, diversidade temática, interatividade e complexidade textual, além de refletirem diferentes usos políticos e institucionais do discurso parlamentar (BLANCO, 2025, 2026). Essas características tornam o corpus adequado

para uma investigação aplicada sobre avaliação de RAG, pois exigem recuperar evidências em acervo heterogêneo, preservar autoria e contexto, lidar com perguntas de complexidade variável e reconhecer situações em que a informação disponível não sustenta resposta conclusiva.

O tema desta pesquisa, portanto, é o estudo e a aplicação de técnicas de avaliação de sistemas RAG em um sistema voltado à consulta de discursos da 56^a Legislatura do Senado Federal, recorte escolhido por oferecer delimitação temporal controlada, volume documental expressivo — aproximadamente 15 mil discursos — e viabilidade de tratamento empírico do **corpus**. Esse recorte permite examinar, em condições observáveis, como diferentes técnicas de avaliação podem capturar dimensões complementares da qualidade das respostas e das evidências recuperadas, tais como pertinência das evidências, fidelidade ao contexto recuperado, precisão de autoria, utilidade da resposta, tratamento da insuficiência documental (ES et al., 2023; SAAD-FALCON et al., 2024; PIPITONE; HOUIR ALAMI, 2024).

1.2. Apresentação da problemática e da pergunta de pesquisa

O problema de pesquisa decorre da lacuna quanto a um protocolo articulado para organizar e aplicar técnicas de avaliação de sistemas RAG em domínios institucionais específicos. Essa lacuna será examinada empiricamente a partir de um sistema RAG voltado à consulta de discursos da 56^a Legislatura do Senado Federal, utilizado como caso empírico para analisar recuperação documental, geração de respostas e verificabilidade das fontes.

Órgãos públicos acumulam acervos de alto valor institucional, mas a adoção de sistemas generativos para explorá-los exige critérios capazes de indicar quando uma resposta é útil, verificável e suficientemente ancorada nas fontes. A literatura sobre RAG já propõe métricas, benchmarks, rubricas, avaliações humanas e estratégias baseadas no paradigma *LLM-as-a-judge*, mas ainda há desafios para organizar essas técnicas em um protocolo aplicável a contextos institucionais específicos, nos quais recuperação, geração e verificabilidade das fontes precisam ser analisadas em conjunto (GAO et al., 2023; ES et al., 2023; SAAD-FALCON et al., 2024; LIU, S. et al., 2025).

Em contextos jurídico-legislativos, estudos já exploram RAG, LLMs e recuperação semântica em legislação, parlamentos e política, incluindo *fact-checking* político e redação legislativa (KHALIQ et al., 2024; CHOUHAN; GERTZ, 2024), consulta a legislação extensa e interfaces conversacionais (GARRISON et al., 2024; ROGIERS et al., 2024; MATOSHI et al., 2025), além de sistemas híbridos com grafos de conhecimento (COLOMBO et al., 2025; MOSBACH et al., 2025). No contexto brasileiro, há estudos sobre discursos parlamentares e organização do conhecimento legislativo (BLANCO, 2025, 2026; MARTELLOTE VIOLA et al., 2025). Ainda assim, permanece^a lacuna quanto à organização de técnicas de avaliação de RAG, de forma articulada, para analisar recuperação documental,

geração de respostas e verificabilidade das fontes em acervos legislativos brasileiros.

Diante disso, formula-se a seguinte pergunta de pesquisa: **como técnicas de avaliação de sistemas RAG podem ser organizadas e aplicadas à análise da recuperação documental, da geração de respostas e da verificabilidade das fontes em um sistema voltado à consulta de discursos da 56^a Legislatura do Senado Federal?**

A justificativa prática da pesquisa está na necessidade de avaliar, com critérios explícitos, sistemas generativos aplicados a acervos documentais de interesse público (WESTMINSTER FOUNDATION FOR DEMOCRACY, 2023; INTER-PARLIAMENTARY UNION, 2024; ALMEIDA; SANTOS JÚNIOR, 2025). Sistemas RAG podem ampliar a mediação entre usuários e documentos legislativos, mas seu uso institucional exige critérios capazes de indicar quando a resposta está adequadamente ancorada em fontes, quando extrapola o contexto recuperado e quando deve explicitar incerteza ou insuficiência documental. Assim, a contribuição esperada não está em defender a adoção automática de sistemas generativos, mas em oferecer uma forma mais criteriosa de avaliá-los antes de qualquer uso ampliado.

No plano científico, a pesquisa se justifica porque a avaliação de RAG ainda é um campo em consolidação, especialmente quando transposta de *benchmarks* genéricos para domínios públicos específicos. Métricas de recuperação, rubricas de geração, avaliação humana e avaliações baseadas no paradigma *LLM-as-a-judge* medem dimensões complementares, mas nenhuma delas, isoladamente, resolve o problema de verificar qualidade, rastreabilidade e verificabilidade das fontes. Ao tratar o protocolo avaliativo como artefato metodológico aplicado a um sistema RAG em contexto institucional, a dissertação pretende organizar essas técnicas e aplicá-las a um corpus legislativo brasileiro (HEVNER et al., 2004; PEFFERS et al., 2007), distinguindo dimensões que, na prática, tendem a aparecer sobrepostas: recuperação documental, geração de respostas, julgamento automatizado, validação humana e verificabilidade das fontes (ES et al., 2023; SAAD-FALCON et al., 2024; PIPITONE; HOUIR ALAMI, 2024).

Por que as referências a DSR aqui?

1.3. Enunciação dos objetivos

1.3.1. GERAL

Organizar técnicas de avaliação de sistemas RAG em um protocolo articulado e aplicá-lo a um caso empírico de consulta a discursos da 56^a Legislatura do Senado Federal, com foco na recuperação documental, na geração de respostas e na verificabilidade das fontes.

Iniciar com
maiúsculas

1.3.2. ESPECÍFICOS

1. sistematizar a literatura sobre técnicas de avaliação de RAG, incluindo métricas de recuperação, avaliação de geração, benchmarks, rubricas, avaliação humana e avaliações baseadas no paradigma *LLM-as-a-judge*;
2. selecionar, a partir da sistematização da literatura, técnicas de avaliação de RAG a serem aplicadas ao caso empírico, contemplando recuperação documental, geração de respostas e verificabilidade das fontes;
3. caracterizar o acervo de discursos parlamentares da 56^a Legislatura do Senado Federal como caso empírico da pesquisa;
4. construir uma bateria de perguntas de teste, com categorias, respostas esperadas e evidências documentais de referência;
5. aplicar ao caso empírico o protocolo de avaliação organizado a partir das técnicas selecionadas;
6. analisar a complementaridade e os limites das técnicas avaliativas quando aplicadas a um acervo legislativo real, com foco na recuperação documental, na geração de respostas e na verificabilidade das fontes.

Em conjunto, esses objetivos conectam três níveis do estudo: a sistematização conceitual das técnicas de avaliação, a organização dessas técnicas em protocolo empírico e a análise dos resultados no contexto do corpus legislativo. Essa sequência busca garantir que a pergunta de pesquisa seja respondida por evidências observáveis, e não apenas por revisão bibliográfica ou demonstração técnica isolada.

2. REFERENCIAL TEÓRICO

Esta seção organiza os fundamentos teóricos que sustentam a pergunta de pesquisa e a delimitação conceitual do projeto. O argumento está estruturado em três eixos complementares: a relação entre inteligência artificial generativa, RAG e recuperação da informação; as especificidades da informação legislativa como acervo público; e os critérios de avaliação aplicáveis a sistemas RAG em domínios institucionais.

2.1. Inteligência artificial generativa, RAG e recuperação da informação

Os grandes modelos de linguagem ampliaram a capacidade de interação com sistemas computacionais por meio de linguagem natural, viabilizando tarefas de sumarização, classificação, geração de texto, resposta a perguntas e apoio à análise documental (BROWN et al., 2020; ZHAO et al., 2023; MINAEE et al., 2024). A arquitetura dominante desses modelos se apoia em avanços associados aos *transformers*, combinados a

estratégias de pré-treinamento em larga escala e ajuste para seguir instruções (VASWANI et al., 2017; BROWN et al., 2020; OUYANG et al., 2022). Apesar dessas capacidades, LLMs não são mecanismos de recuperação documental por definição: suas respostas podem refletir padrões aprendidos no treinamento, inferências probabilísticas e lacunas de atualização, sem indicar de forma confiável quais documentos sustentam cada afirmação (JI et al., 2023; ANH-HOANG et al., 2025; DAHL et al., 2024).

O RAG surge como uma estratégia para aproximar geração textual e recuperação da informação. Na formulação clássica, a arquitetura combina um mecanismo de recuperação sobre uma base documental externa com um modelo generativo que produz a resposta a partir do contexto recuperado (LEWIS et al., 2020). Revisões recentes classificam essas arquiteturas em configurações ingênuas, avançadas e modulares, destacando que o desempenho depende de todo o pipeline, não apenas do modelo final de geração (GAO et al., 2023, 2024). Componentes como extração documental, segmentação em *chunks*, enriquecimento por metadados, geração de *embeddings*, recuperação vetorial, reranking, seleção de contexto e *prompting* orientado a evidências influenciam diretamente a qualidade das respostas (GUPTA et al., 2024; NIE et al., 2024).

No componente de recuperação, o problema se aproxima da tradição de recuperação da informação, que envolve representação de documentos, formulação de consultas, ranqueamento e avaliação da pertinência dos resultados recuperados (MANNING et al., 2008). Em sistemas RAG, essa etapa é frequentemente operacionalizada por recuperação densa ou vetorial, em que representações semânticas são usadas para localizar passagens relevantes ao contexto da consulta (KARPUKHIN et al., 2020; THAKUR et al., 2021).

Essa literatura é central para o projeto porque desloca a análise de uma discussão genérica sobre “uso de IA” para uma questão avaliativa delimitada: em que condições uma arquitetura RAG recupera evidências pertinentes, gera respostas verificáveis e reconhece limites de escopo. Essa delimitação exige distinguir, no desenho da pesquisa, a recuperação documental, a geração de respostas e o julgamento das respostas.

2.2. Informação legislativa, transparência e acervos parlamentares

O acesso à informação pública é dimensão central da administração democrática, mas a disponibilidade formal de documentos não elimina barreiras de compreensão, localização e uso qualificado. No domínio legislativo, discursos, debates e registros parlamentares são fontes relevantes para reconstruir posicionamentos, agendas, conflitos, justificativas e memória institucional (SKUBIC; FIŠER, 2024). Ao mesmo tempo, esses acervos podem ser difíceis de explorar por mecanismos convencionais de busca, sobretudo quando o usuário não conhece previamente a terminologia exata, os atores envolvidos ou a organização dos registros (BANDEIRA; BERNARDES, 2016; GEUNIS, 2023).

No caso brasileiro, estudos recentes da Consultoria Legislativa do Senado mostram que os pronunciamentos em plenário formam um corpus extenso, dinâmico e analítica-

mente relevante, com variações de volume, extensão, interatividade e complexidade textual ao longo do tempo (BLANCO, 2025, 2026). Em paralelo, pesquisas sobre organização do conhecimento legislativo indicam que o uso de inteligência artificial nesse domínio precisa considerar estrutura informacional, explicabilidade, mediação documental e confiabilidade dos resultados (MARTELLOTE VIOLA et al., 2025).

Assim, a informação legislativa não deve ser tratada apenas como massa textual a ser processada. Trata-se de um recurso institucional, marcado por regras de produção, metadados, autoria, temporalidade, retificações, usos políticos e requisitos de accountability (BANDEIRA; BERNARDES, 2016; MARTELLOTE VIOLA et al., 2025). Essa característica reforça a necessidade de combinar inovação técnica com critérios de avaliação compatíveis com o uso público e institucional da informação legislativa.

2.3. Avaliação de sistemas RAG em domínios institucionais

A avaliação de sistemas RAG apresenta desafios próprios porque uma resposta final aparentemente correta pode ocultar recuperação deficiente, uso inadequado das fontes, extrapolação além do contexto ou julgamento automatizado permissivo. Essa dificuldade se relaciona ao caráter multidimensional da avaliação de sistemas baseados em modelos de linguagem, nos quais diferentes dimensões de desempenho, confiabilidade e uso precisam ser analisadas de forma articulada (LIANG et al., 2023). Por isso, a literatura recomenda distinguir métricas de recuperação, critérios de avaliação da geração, avaliação humana, avaliação automatizada baseada em LLMs e análise qualitativa de erros (SAAD-FALCON et al., 2024; ES et al., 2023; PIPITONE; HOUIR ALAMI, 2024). Benchmarks recentes também apontam a importância de testar diferentes famílias de perguntas, como questões factuais, comparativas, temporais, multietapas, numéricas e não respondíveis (ZHU et al., 2025).

Entre essas técnicas, o paradigma *LLM-as-a-judge* merece atenção específica neste projeto porque permite avaliar respostas geradas com base em rubricas explícitas (LIU, Y. et al., 2023; LIU, S. et al., 2025). Essa abordagem pode ajudar a escalar avaliações, mas não elimina a necessidade de validação humana, pois o julgamento automatizado pode variar conforme modelo, rubrica, formato de entrada e complexidade da tarefa. Em domínios públicos, esse ponto é decisivo: uma avaliação automatizada não deve ser confundida com certificação de qualidade institucional.

Em domínios públicos, diretrizes e estudos sobre IA enfatizam transparência, finalidade pública, supervisão humana e responsabilização (INTER-PARLIAMENTARY UNION, 2024; WESTMINSTER FOUNDATION FOR DEMOCRACY, 2023; ALMEIDA; SANTOS JÚNIOR, 2025). Nesta pesquisa, esses elementos são tratados como contexto institucional para justificar a necessidade de avaliação criteriosa, e não como dimensão autônoma do protocolo. O protocolo concentra-se em aspectos diretamente observáveis no sistema RAG: recuperação documental, geração de respostas, indicação

das fontes, explicitação de insuficiência documental e verificabilidade das fontes.

Nesse contexto, **protocolo é entendido** como uma organização explícita de procedimentos, métricas, rubricas e critérios de interpretação voltados a avaliar, de forma reprodutível, dimensões complementares de um sistema RAG.

2.4. Lacuna de pesquisa

A literatura existente oferece bases técnicas para compreender arquiteturas RAG, avaliação de respostas geradas e recuperação da informação, bem como estudos sobre informação legislativa e parlamentos. Entretanto, os trabalhos mais próximos distribuem-se em frentes ainda pouco integradas. Estudos sobre RAG enfatizam arquitetura, recuperação, geração e avaliação automatizada, mas frequentemente tratam domínios genéricos ou jurídicos mais amplos (GAO et al., 2023; SAAD-FALCON et al., 2024; ES et al., 2023; PIPITONE; HOUIR ALAMI, 2024). Pesquisas sobre parlamentos e informação legislativa discutem acesso, transparência, discurso parlamentar e organização do conhecimento, mas nem sempre implementam ou avaliam sistemas conversacionais baseados em RAG (SKUBIC; FIŠER, 2024; BLANCO, 2025, 2026; MARTELLOTE VIOLA et al., 2025). Aplicações recentes em legislação e política, por sua vez, exploram **fact-checking**, redação legislativa, consulta a textos normativos, interfaces conversacionais e arquiteturas híbridas, mas diferem quanto a **corpus**, língua, jurisdição, tarefa e desenho de avaliação (KHALIQ et al., 2024; CHOUHAN; GERTZ, 2024; GARRISON et al., 2024; ROGIERIS et al., 2024; MATOSHI et al., 2025; COLOMBO et al., 2025; MOSBACH et al., 2025).

Desse modo, a lacuna refere-se à escassez de estudos empíricos que combinem, no mesmo desenho de pesquisa e no contexto brasileiro, um acervo parlamentar real, um *pipeline* RAG reprodutível, avaliação formal da recuperação documental, avaliação das respostas geradas e análise da verificabilidade das fontes. No caso desta pesquisa, essa lacuna será examinada em discursos da 56^a Legislatura do Senado Federal, com atenção simultânea à recuperação, à geração e à verificabilidade das fontes. O foco do estudo recai sobre a forma como a recuperação documental, a geração de respostas e a verificabilidade das fontes podem ser avaliadas de maneira articulada em consultas legislativas mediadas por RAG.

Essa lacuna é especialmente relevante para a administração pública, pois envolve simultaneamente organização de um protocolo avaliativo, avaliação empírica e uso de acervos institucionais de interesse público. A dissertação proposta busca contribuir para esse espaço ao desenvolver uma investigação com critérios explícitos para avaliação de sistemas RAG em acervos legislativos.

3. HIPÓTESES DO ESTUDO

Esta pesquisa caracteriza-se como investigação aplicada, multimétodos e orientada à organização e aplicação de um protocolo avaliativo a um sistema RAG em contexto institucional. Nesse contexto, as hipóteses assumem a forma de hipóteses de trabalho verificáveis, funcionando como respostas provisórias ao problema de pesquisa que poderão ser corroboradas, qualificadas ou rejeitadas pelas evidências empíricas produzidas no estudo. Desse modo, não serão tratadas como teste causal clássico entre uma variável independente e uma variável dependente única. Essa opção é compatível com a *Design Science Research*, na qual a construção e a avaliação de artefatos constituem parte do processo de produção de conhecimento (HEVNER et al., 2004; PEFFERS et al., 2007).

As hipóteses de trabalho são as seguintes:

- H1. A pertinência das evidências recuperadas é condição necessária, mas não suficiente, para a verificabilidade das respostas.** A hipótese será examinada pela análise de dois padrões complementares. O primeiro corresponde à ausência de evidência pertinente recuperada para sustentar afirmações presentes na resposta, situação em que a verificabilidade documental fica comprometida. O segundo corresponde aos casos em que há evidência pertinente recuperada, mas a resposta permanece não verificável porque a geração não associa explicitamente as afirmações às evidências recuperadas, utiliza inadequadamente essas evidências ou extrapola o contexto recuperado. A hipótese será considerada corroborada se a análise empírica identificar a ocorrência dos dois padrões em casos documentados. Será qualificada se esses padrões ocorrerem apenas em determinados tipos de pergunta ou sob condições específicas, e será rejeitada se a verificabilidade das respostas puder ser explicada integralmente pela qualidade da recuperação documental.
- H2. O desempenho do sistema tende a ser inferior em perguntas que exigem integração de múltiplas evidências, raciocínio em etapas ou reconhecimento de informação ausente, em comparação com perguntas factuais simples, delimitadas por autor e apoiadas em evidência documental direta.** A hipótese será examinada por meio de uma bateria de perguntas organizada por categorias operacionais, com comparação de desempenho agregado e análise de erro entre grupos de categorias. Será considerada corroborada se as categorias de maior complexidade apresentarem desempenho inferior ao das categorias simples de forma consistente nos critérios aplicados ao protocolo avaliativo. Será qualificada se essa diferença ocorrer apenas em determinados tipos de pergunta, dimensões avaliativas ou condições específicas, e será rejeitada se o desempenho se mostrar homogêneo entre as categorias ou inverso ao esperado. Essa expectativa direcional deriva de benchmarks e estudos de avaliação de RAG, que mostram variação de desempenho

conforme a complexidade da pergunta, a necessidade de integração de evidências e a presença de questões não respondíveis (SAAD-FALCON et al., 2024; ES et al., 2023; ZHU et al., 2025; PIPITONE; HOUIR ALAMI, 2024).

H3. A avaliação baseada no paradigma *LLM-as-a-judge* apresentará concordância parcial com a avaliação humana, mas será insuficiente como critério único de qualidade. A hipótese será examinada pela comparação entre julgamentos automatizados e avaliação humana independente. Será considerada corroborada se a avaliação automatizada apresentar concordância parcial com a avaliação humana, mas também revelar divergências suficientes para impedir seu uso como critério único de qualidade. Será qualificada se a concordância variar conforme o tipo de pergunta, a dimensão avaliada ou a formulação da rubrica, e será rejeitada se os julgamentos automatizados se mostrarem plenamente consistentes com a avaliação humana ou, inversamente, incapazes de discriminar diferenças de qualidade segundo os critérios da rubrica. Essa hipótese se fundamenta na literatura sobre avaliação automatizada de linguagem natural e sobre uso de LLMs como avaliadores, que aponta sensibilidade a rubricas, modelos e formato de entrada (LIU, Y. et al., 2023; LIU, S. et al., 2025).

Em conjunto, essas hipóteses orientam a organização da bateria de perguntas, a seleção dos critérios avaliativos e a interpretação dos resultados empíricos. Seu papel é estruturar a análise da recuperação documental, da geração de respostas e da verificabilidade das fontes, sem antecipar conclusões e sem converter o estudo em um teste causal clássico entre variáveis isoladas.

4. METODOLOGIA

4.1. Natureza e abordagem da pesquisa

A pesquisa proposta possui natureza aplicada, exploratória e descritiva. É aplicada porque se volta a um problema concreto da administração pública: a necessidade de avaliar, com critérios explícitos, sistemas RAG voltados à consulta verificável de acervos legislativos extensos, tomando como caso empírico discursos parlamentares da 56^a Legislatura do Senado Federal. É exploratória porque investiga a organização e a aplicação de um protocolo de avaliação de sistemas RAG, considerando a articulação entre recuperação documental, geração de respostas e verificabilidade das fontes. É descritiva porque caracteriza os resultados empíricos da aplicação do protocolo avaliativo a um sistema RAG, à luz das dimensões e dos critérios previamente definidos no estudo. Essa classificação segue a orientação metodológica de explicitar a natureza da pesquisa em função do problema investigado e do tipo de evidência necessário para respondê-lo (GIL, 2022).

Quanto ao método de abordagem, a pesquisa terá orientação predominantemente hipotético-dedutiva, pois parte de hipóteses de trabalho e de critérios avaliativos previamente definidos, mas incorporará componente indutivo ao identificar padrões de erro emergentes e formular recomendações a partir dos resultados observados. Essas hipóteses são derivadas principalmente da literatura sobre RAG, recuperação da informação e avaliação de sistemas generativos, sendo contextualizadas pela literatura sobre informação legislativa em contexto público; em seguida, serão confrontadas com evidências empíricas obtidas no caso estudado. Ao mesmo tempo, o exame dos casos críticos poderá revelar padrões não previstos inicialmente, que serão usados para refinar recomendações metodológicas e institucionais. Essa combinação é adequada porque o projeto confronta respostas provisórias ao problema de pesquisa com evidências observáveis, mas também admite aprendizado a partir da observação sistemática dos resultados (LAKATOS; MARCONI, 2021). Essa orientação não implica teste causal clássico entre variáveis isoladas; as hipóteses serão examinadas por meio de critérios definidos no protocolo avaliativo e aplicados ao sistema RAG, às respostas geradas e ao corpus estudado.

A abordagem será multimétodos. A dimensão quantitativa aparecerá na mensuração da recuperação documental, na avaliação estruturada da geração de respostas e na avaliação da verificabilidade das fontes, por meio de métricas por categoria de pergunta e, quando aplicável, medidas de concordância entre julgamentos humanos e automatizados. A dimensão qualitativa estará presente na análise de erros, na interpretação das divergências entre avaliadores humanos e *LLM-as-a-judge*, na interpretação institucional dos resultados e na leitura contextualizada de respostas representativas. O uso combinado de estratégias quantitativas e qualitativas é pertinente porque o fenômeno investigado envolve tanto desempenho mensurável quanto adequação institucional, qualidade argumentativa, interpretação documental e riscos de uso (CRESWELL; PLANO CLARK, 2018).

Como delineamento, a dissertação combinará pesquisa bibliográfica, pesquisa documental, estudo de caso aplicado e aplicação controlada do protocolo avaliativo. A pesquisa bibliográfica sistematizará literatura sobre RAG, avaliação de sistemas generativos, recuperação da informação, informação legislativa e uso institucional de IA. A pesquisa documental trabalhará com discursos parlamentares e metadados legislativos públicos. O estudo de caso concentrará a análise em um sistema RAG aplicado aos discursos da 56ª Legislatura do Senado Federal. A aplicação controlada do protocolo avaliativo será usada para avaliar comparativamente a recuperação documental, a geração de respostas e a verificabilidade das fontes, sob critérios previamente definidos, sem pretensão de generalizar os resultados para todas as arquiteturas RAG.

O enquadramento geral dialoga com a *Design Science Research*, pois a dissertação organizará e aplicará um protocolo avaliativo como artefato metodológico voltado a enfrentar um problema relevante de informação pública, tendo um sistema RAG como caso empírico de aplicação (HEVNER et al., 2004; PEFFERS et al., 2007).

4.2. Fundamentação empírica: dados e técnicas de coleta

O **corpus** documental da pesquisa será composto por discursos parlamentares da 56^a Legislatura do Senado Federal, derivados de registros públicos previamente organizados em dataset aberto. A pesquisa utilizará dados secundários, de natureza pública e documental, sem coleta direta de informações junto a participantes humanos para construção do **corpus**. Serão registrados, quando disponíveis, metadados como data, autor, partido, unidade federativa, tipo de uso da palavra, resumo, indexação e URL do discurso original. O protocolo avaliativo constitui o artefato principal da pesquisa, enquanto o sistema RAG construído sobre o **corpus** funcionará como caso empírico para sua aplicação e análise.

As técnicas de coleta serão organizadas em três frentes, correspondentes às fontes teóricas e normativas da pesquisa, à constituição do **corpus** documental e ao registro dos resultados produzidos pela aplicação do protocolo avaliativo. A primeira frente será bibliográfica e técnico-normativa, com levantamento de artigos, **surveys**, **benchmarks**, relatórios institucionais e diretrizes sobre RAG, avaliação de sistemas generativos, informação legislativa e uso institucional de IA. A segunda frente será documental, com coleta, congelamento e registro de versão do **corpus** de discursos parlamentares e de seus metadados. A terceira frente será avaliativa, com registro das evidências recuperadas, das respostas geradas e dos julgamentos humanos e automatizados previstos no protocolo avaliativo, incluindo aqueles baseados no paradigma *LLM-as-a-judge*.

A coleta e organização dos dados envolverão as seguintes etapas:

1. congelamento de uma versão do corpus e registro de manifesto de dados, versões e *hashes*;
2. preparação textual e segmentação dos documentos em unidades recuperáveis;
3. enriquecimento dos trechos com metadados legislativos;
4. ingestão em base vetorial e configuração do fluxo RAG;
5. construção de bateria de perguntas de teste, balanceada por categorias;
6. elaboração de conjunto de referência para recuperação, com trechos recuperáveis esperados por pergunta, preservada sua vinculação ao discurso original;
7. aplicação do protocolo avaliativo ao sistema RAG, com registro das evidências recuperadas e das respostas geradas;
8. coleta de julgamentos humanos independentes e de julgamentos automatizados auxiliares baseados no paradigma *LLM-as-a-judge*.

Serão incluídos apenas discursos com texto disponível e metadados mínimos de identificação. Registros duplicados, incompletos ou sem referência documental verificável serão tratados conforme regras registradas no manifesto de dados.

As categorias de perguntas incluirão questões factuais, foco em autor, desambiguação, evidência negativa, comparação entre autores, comparação temporal, pergunta numérica, síntese temática, pergunta multietapas, autoria cruzada, controle de escopo e estresse de recuperação. A escolha dessas categorias se fundamenta em três critérios. Primeiro, elas dialogam com famílias de tarefas recorrentes em benchmarks e avaliações de RAG, como perguntas factuais, integração de informações, comparação, raciocínio em múltiplas etapas, síntese e perguntas não respondíveis (ZHU et al., 2025; SAAD-FALCON et al., 2024; ES et al., 2023). Segundo, contemplam dimensões particularmente relevantes para domínios jurídicos e legislativos, nos quais a qualidade da resposta depende não apenas de fluência, mas também de recuperação da fonte pertinente, fidelidade ao contexto, precisão de autoria, evidência suficiente e abstinência diante de informação ausente ou ambígua (PIPITONE; HOUIR ALAMI, 2024; DAHL et al., 2024). Terceiro, incorporam riscos observáveis no próprio domínio empírico dos discursos parlamentares, como variação terminológica, dispersão temporal, multiplicidade de autores, presença de discursos sobre temas semelhantes e necessidade de distinguir consulta exploratória de afirmação documental verificável (BLANCO, 2025, 2026; MARTELLOTE VIOLA et al., 2025).

A distribuição das perguntas será organizada de modo a preservar representação mínima por categoria, evitando concentração excessiva em perguntas factuais simples e permitindo avaliar diferentes níveis de complexidade da recuperação documental, da geração de respostas e da verificabilidade das fontes.

O conjunto de referência será construído por curadoria documental, com registro das evidências consideradas suficientes para cada pergunta respondível. Quando houver ambiguidade sobre a suficiência da evidência, o caso será submetido a revisão, com registro da decisão adotada. Perguntas não respondíveis terão essa condição registrada explicitamente, para permitir avaliar a capacidade do sistema de explicitar insuficiência documental e, quando apropriado, abster-se de responder.

Serão documentados os principais parâmetros do pipeline, incluindo estratégia de segmentação, tamanho e sobreposição dos trechos, metadados utilizados, modelo de *embedding*, base vetorial, estratégia de busca, valor de **top-k**, ^{top-p pode ser mais interessante}, reranqueamento, se utilizado, *prompt* de geração, modelo gerador, temperatura, data de execução e versões de ferramentas ou serviços utilizados.

4.3. Técnicas de análise dos dados e matriz de opções metodológicas

A análise dos dados será organizada em quatro camadas. A primeira avaliará a recuperação documental por meio de métricas de recuperação ranqueada consolidadas na literatura de recuperação da informação, como *Recall@k*, *Precision@k*, MRR e nDCG

(MANNING et al., 2008), também empregadas em benchmarks contemporâneos de recuperação como o BEIR (THAKUR et al., 2021). Adicionalmente, poderá ser usado *Hit@k*, entendido como medida operacional de acerto no topo da lista, isto é, a presença de pelo menos uma evidência relevante entre os k primeiros resultados, conforme a granularidade do conjunto de referência.

Para fins de avaliação da recuperação, a unidade principal de análise será o trecho recuperável indexado no sistema, preservada sua vinculação ao discurso original, aos metadados e à URL da fonte. Quando a evidência esperada corresponder a um discurso inteiro, serão considerados relevantes os trechos desse discurso que contenham informação suficiente para responder à pergunta.

Recall@k indicará se as evidências esperadas aparecem entre os resultados recuperados; Precision@k indicará a proporção de itens relevantes entre os recuperados; MRR observará a posição da primeira evidência relevante; nDCG considerará a ordenação das evidências por grau de relevância; Hit@k indicará se ao menos uma evidência suficiente foi recuperada entre os primeiros resultados.

O uso de *Precision@k* e nDCG dependerá da granularidade do conjunto de referência e da possibilidade de classificar os itens recuperados como relevantes, parcialmente relevantes ou irrelevantes. Caso o conjunto de referência registre apenas evidências suficientes por pergunta, a análise priorizará *Hit@k*, *Recall@k* e MRR, mantendo *Precision@k* e nDCG apenas quando houver julgamento de relevância suficientemente detalhado para sua aplicação.

A segunda camada avaliará a geração de respostas por rubrica, considerando correção factual, aderência ao contexto recuperado, fidelidade às fontes, precisão de autoria, explicitação de insuficiência documental, completude proporcional e ausência de alucinação. A terceira camada comparará avaliação humana e avaliação baseada no paradigma *LLM-as-a-judge*, observando concordâncias, divergências, falsos positivos de qualidade e falsos negativos. A quarta camada analisará qualitativamente erros e casos críticos, buscando identificar padrões como falhas de recuperação, uso inadequado de fontes, atribuição incorreta, extrapolação do contexto recuperado, resposta sem evidência suficiente e ausência de explicitação de insuficiência documental.

Essas camadas operacionalizam as hipóteses do estudo e mantêm correspondência direta com os objetivos específicos. A sistematização da literatura orientará a seleção das métricas, rubricas e categorias de pergunta. A caracterização do acervo delimitará o corpus, os metadados e os riscos documentais relevantes. A bateria de perguntas e o conjunto de referência permitirão examinar recuperação documental, geração de respostas e verificabilidade das fontes em condições controladas. A comparação entre avaliação humana e avaliação baseada no paradigma *LLM-as-a-judge* permitirá examinar o alcance do julgamento automatizado. Por fim, a análise qualitativa dos erros e casos críticos sustentará a discussão sobre limites, riscos e condições de interpretação dos resultados em

contexto institucional. Assim, a verificabilidade será examinada pela relação entre evidências recuperadas, fontes citadas e afirmações geradas; a variação por tipo de pergunta será analisada por desempenho agregado e padrões de erro; o alcance da avaliação baseada no paradigma *LLM-as-a-judge* será avaliado pela comparação com julgamentos humanos independentes; e as condições de interpretação e uso cauteloso serão discutidas a partir dos resultados técnicos, dos casos críticos e dos requisitos institucionais identificados na literatura.

O protocolo avaliativo incluirá: aplicação a um sistema RAG construído sobre o corpus documental; bateria de perguntas distribuída por categorias; conjunto de referência com evidências documentais associadas às perguntas respondíveis; registro das evidências recuperadas e das respostas geradas; avaliação humana independente de uma amostra de respostas; e avaliação auxiliar baseada no paradigma *LLM-as-a-judge*. Esses componentes serão utilizados para examinar recuperação documental, geração de respostas e verificabilidade das fontes, sem pretensão de comparar arquiteturas RAG de forma abrangente.

A avaliação humana será organizada por rubrica explícita, preferencialmente aplicada por pelo menos **dois avaliadores independentes** com familiaridade mínima com documentação legislativa ou com avaliação de sistemas de informação. Antes da anotação principal, será realizado piloto com amostra reduzida de perguntas para calibrar instruções, exemplos positivos, exemplos negativos e casos limítrofes. Sempre que viável, os avaliadores não terão acesso à identidade do sistema que gerou cada resposta. Divergências serão registradas e, quando necessário, dirimidas por revisão conjunta ou por avaliador adicional. A concordância entre julgamentos será descrita por percentual de acordo e pela análise das divergências observadas. A interpretação dos resultados será cautelosa e proporcional ao desenho amostral, evitando apresentar médias agregadas ou percentuais de concordância como prova isolada de qualidade.

Os avaliadores serão informados sobre a finalidade da avaliação, o uso dos resultados e a forma de registro das respostas, preservando-se sua identificação individual na apresentação dos resultados.

Para o julgamento automatizado, serão registrados modelo, versão, *prompt*, rubrica, temperatura, formato de entrada e data de execução. Sempre que viável, o julgamento será repetido ou validado em amostra piloto para observar estabilidade. Os resultados do *LLM-as-a-judge* serão tratados como auxiliares e comparados à avaliação humana, sem função de certificação autônoma.

4.4. Recursos, viabilidade e transparência no uso de IA

A viabilidade da pesquisa depende de quatro condições principais. A primeira é a disponibilidade do corpus, composto por dados públicos e secundários, o que reduz riscos de acesso e dispensa coleta direta de dados pessoais sensíveis junto a participantes huma-

nos para constituição da base documental. A segunda é a infraestrutura computacional para preparação textual, indexação vetorial, execução do sistema RAG, armazenamento de resultados e registro de versões; essa infraestrutura poderá ser composta por ferramentas de código aberto e, quando necessário, por serviços de API para geração ou julgamento automatizado. A terceira é a disponibilidade de avaliadores humanos para aplicar rubrica explícita a uma amostra das respostas; por isso, a avaliação humana será tratada como etapa amostral, com piloto prévio e escopo ajustável ao número efetivo de avaliadores. A quarta é o controle de custos e tempo de execução, que será enfrentado pela delimitação do protocolo avaliativo, pela aplicação a um corpus documental específico e pela realização da avaliação humana em amostra de respostas.

O uso de IA generativa na pesquisa será tratado de forma transparente. Modelos de linguagem poderão ser utilizados como componentes do sistema RAG avaliado, como instrumentos auxiliares de julgamento automatizado e, como apoio editorial à revisão de texto, sempre sob responsabilidade do pesquisador. Quando integrarem a coleta ou a análise dos dados, serão registrados modelo, versão ou provedor disponível, configuração relevante, rubrica, prompt ou instruções de julgamento e data de execução. As saídas automatizadas não serão tratadas como evidência autossuficiente: deverão ser confrontadas com fontes documentais, métricas de recuperação, rubricas e avaliação humana nos limites definidos pelo protocolo.

A seguir apresenta-se a matriz preliminar de opções metodológicas que a pesquisa empregará:

Tabela 1: Matriz preliminar de opções metodológicas

Objetivo específico	Abordagem	Natureza	Dados coletados	Público-alvo	Amostragem	Técnicas de coleta	Técnicas de análise	Apresentação
Sistematizar literatura sobre avaliação de RAG	Qualitativa	Exploratória	Artigos, relatórios, diretrizes e benchmarks	Pesquisadores e gestores públicos	Intencional por pertinência temática	Pesquisa bibliográfica e documental	Síntese crítica por temas e lacunas	Texto e quadro-síntese
Selecionar técnicas de avaliação aplicáveis ao caso	Multimétodos	Exploratória	Métricas, rubricas, critérios e protocolos	Gestores, equipes técnicas e avaliadores	Seleção por adequação ao problema	Fichamento e análise de protocolos	Comparação metodológica e análise de viabilidade	Protocolo de avaliação
Caracterizar o acervo legislativo	Qualitativa	Descritiva	Discursos, metadados e documentação do corpus	Usuários de informação legislativa	Corpus da 56ª Legislatura	Pesquisa documental e registro de versões	Caracterização documental e análise de metadados	Descrição do corpus
Construir bateria e conjunto de referência	Multimétodos	Exploratória	Perguntas, respostas esperadas e evidências	Avaliadores e pesquisadores	Perguntas balanceadas por categoria	Curadoria documental e anotação das evidências	Categorização, revisão e validação	Bateria e quadro de evidências
Avaliar recuperação documental	Quantitativa	Descritiva	Trechos recuperados e evidências esperadas	Equipes técnicas e pesquisadores	Perguntas da bateria	Execuções controladas do protocolo avaliativo	Hit@k, Recall@k, Precision@k, MRR e nDCG	Tabelas e gráficos
Avaliar geração e julgamentos	Multimétodos	Descritiva	Respostas, notas humanas e notas de avaliação baseada no paradigma <i>LLM-as-a-judge</i>	Avaliadores humanos e gestores	Amostra de respostas, preservando representação das categorias de pergunta	Rubrica humana, piloto e avaliação baseada no paradigma <i>LLM-as-a-judge</i>	Estatísticas, concordância e análise de erros	Tabelas, exemplos e discussão
Analisar limites e condições de interpretação dos resultados	Qualitativa	Descritiva	Resultados, erros, divergências avaliativas e casos críticos	Gestores públicos, equipes técnicas e pesquisadores	Casos críticos e achados do protocolo	Síntese dos resultados, análise de erros e seleção de casos representativos	Análise temática de erros, limites e implicações institucionais	Discussão interpretativa e recomendações de uso cauteloso

Fonte: elaborado pelo autor.

5. CRONOGRAMA DA PESQUISA

A seguir apresenta-se a estimativa preliminar das atividades de pesquisa e de seus respectivos prazos. O cronograma toma maio de 2026 como mês inicial e deverá ser ajustado conforme o calendário oficial do programa, a definição de orientação, a qualificação e a disponibilidade de avaliadores humanos.

Tabela 2: Descritivo preliminar de atividades e prazos de entrega

	mai/26	jun/26	jul/26	ago/26	set/26	out/26	nov/26	dez/26	jan/27	fev/27
Atividades de pesquisa										
Início da orientação e refinamento do problema	X	X								
Revisão de literatura e matriz teórica	X	X	X							
Definição do protocolo de avaliação		X	X							
Coleta, tratamento e organização do corpus		X	X	X						
Construção da bateria de perguntas e conjunto de referência			X	X						
Piloto metodológico e ajustes do protocolo				X	X					
Exame de qualificação				X						
Aplicação do protocolo avaliativo ao sistema RAG					X	X				
Avaliação humana e avaliação baseada no paradigma <i>LLM-as-a-judge</i>						X	X			
Análise dos dados e interpretação dos resultados							X	X		
Síntese dos resultados, discussão e recomendações								X	X	
Redação e revisão dos capítulos teóricos e metodológicos	X	X	X	X						
Redação dos resultados, discussão e conclusão							X	X	X	
Depósito da versão final da dissertação									X	
Previsão de defesa da dissertação										X
Elaboração de artigo científico derivado									X	X

Fonte: elaborado pelo autor (2026).

6. REFERÊNCIAS

- ALMEIDA, Patricia Gomes Rêgo de; SANTOS JÚNIOR, Carlos Denner dos. Artificial intelligence governance: Understanding how public organizations implement it. **Government Information Quarterly**, v. 42, n. 1, p. 102003, 2025. DOI: [10.1016/j.giq.2024.102003](https://doi.org/10.1016/j.giq.2024.102003). Disponível em: <https://www.sciencedirect.com/science/article/pii/S0740624X24000959>. Acesso em: 21 abr. 2026.
- ANH-HOANG, Dang; TRAN, Vu; NGUYEN, Le-Minh. Survey and Analysis of Hallucinations in Large Language Models: Attribution to Prompting Strategies or Model Behavior. **Frontiers in Artificial Intelligence**, v. 8, 2025. DOI: [10.3389/frai.2025.1622292](https://doi.org/10.3389/frai.2025.1622292). Disponível em: <https://www.frontiersin.org/articles/10.3389/frai.2025.1622292/full>. Acesso em: 8 abr. 2026.
- BANDEIRA, Cristina Leston; BERNARDES, Cristiane Brum. Information vs Engagement in Parliamentary Websites – A Case Study of Brazil and the UK. **Revista de Sociologia e Política**, v. 24, n. 59, p. 91–107, 2016. DOI: [10.5380/rsocp.v24i59.48709](https://doi.org/10.5380/rsocp.v24i59.48709). Disponível em: <https://revistas.ufpr.br/rsp/article/view/48709>. Acesso em: 9 abr. 2026.
- BLANCO, Pedro Duarte. **Letras graúdas, letras miúdas: leitura e complexidade textual dos discursos em Plenário 2007-2024**. Brasília, fev. 2026. (Texto para Discussão, 357). Disponível em: <https://www12.senado.leg.br/publicacoes/estudos-legislativos/tipos-de-estudos/textos-para-discussao/td357>. Acesso em: 21 abr. 2026.
- _____. **Plenário, Palanque, Estúdio: Discursos no Plenário do Senado Federal entre 2007 e 2024**. Brasília, dez. 2025. (Texto para Discussão, 355). Disponível em: <https://www12.senado.leg.br/publicacoes/estudos-legislativos/tipos-de-estudos/textos-para-discussao/td355>. Acesso em: 21 abr. 2026.
- BROWN, Tom B.; MANN, Benjamin; RYDER, Nick; SUBBIAH, Melanie; KAPLAN, Jared; DHARIWAL, Prafulla; NEELAKANTAN, Arvind; SHYAM, Pranav; SASTRY, Girish; ASKELL, Amanda; AGARWAL, Sandhini; HERBERT-VOSS, Ariel et al. Language Models are Few-Shot Learners. In: **ADVANCES in Neural Information Processing Systems**. Curran Associates, Inc., 2020. v. 33, p. 1877–1901. Disponível em: <https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfbcb4967418bfb8ac142f64a-Abstract.html>. Acesso em: 25 jun. 2026.

CHOUHAN, Ashish; GERTZ, Michael. LexDrafter: Terminology Drafting for Legislative Documents Using Retrieval Augmented Generation. In: PROCEEDINGS of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024). Torino, Italia: ELRA e ICCL, mai. 2024.

P. 10448–10458. Disponível em:

<<https://aclanthology.org/2024.lrec-main.913/>>. Acesso em: 29 abr. 2026.

COLOMBO, Andrea; BERNASCONI, Anna; BELLOMARINI, Luigi; GUIISO, Luigi; MICHELACCI, Claudio; CERI, Stefano. LegisSearch: navigating legislation with graphs and large language models. **Artificial Intelligence and Law**, 2025. DOI:

10.1007/s10506-025-09482-6. Disponível em:

<<https://link.springer.com/article/10.1007/s10506-025-09482-6>>. Acesso em: 29 abr. 2026.

CRESWELL, John W.; PLANO CLARK, Vicki L. **Designing and Conducting Mixed Methods Research**. 3. ed. Thousand Oaks: SAGE Publications, 2018.

DAHL, Matthew; MAGESH, Varun; SUZGUN, Mirac; HO, Daniel E. Large Legal Fictions: Profiling Legal Hallucinations in Large Language Models. **Journal of Legal Analysis**, v. 16, n. 1, p. 64–93, 2024. DOI: 10.1093/jla/laae003. Disponível em:

<<https://academic.oup.com/jla/article/16/1/64/7699227>>. Acesso em: 29 abr. 2026.

ES, Shahul; JAMES, Jithin; ESPINOSA-ANKE, Luis; SCHOCKAERT, Steven. **Ragas: Automated Evaluation of Retrieval Augmented Generation**. 2023. DOI:

10.48550/arXiv.2309.15217. arXiv: 2309.15217. Disponível em:

<<https://arxiv.org/abs/2309.15217>>. Acesso em: 21 abr. 2026.

GAO, Yunfan; XIONG, Yun; GAO, Xinyu; JIA, Kangxiang; PAN, Jinliu; BI, Yuxi; DAI, Yi; SUN, Jiawei; WANG, Meng; WANG, Haofen. **Retrieval-Augmented Generation for Large Language Models: A Survey**. 2023. arXiv: 2312.10997.

Disponível em: <<https://arxiv.org/abs/2312.10997>>. Acesso em: 9 abr. 2026.

GAO, Yunfan; XIONG, Yun; WANG, Meng; WANG, Haofen. **Modular RAG: Transforming RAG Systems into LEGO-like Reconfigurable Frameworks**.

2024. arXiv: 2407.21059. Disponível em: <<https://arxiv.org/abs/2407.21059>>.

Acesso em: 9 abr. 2026.

GARRISON, Kevin; FISHER, William M.; BERGE, Astrid I. **Talk to the NDAA: Evaluating Retrieval Augmented Generation (RAG) on Congressional Legislation using Large Language Models (LLM)**. Alexandria, Virginia, ago. 2024.

Disponível em: <<https://www.ida.org/-/media/feature/publications/t/ta/talk-to-the-ndaa/3001199.ashx>>. Acesso em: 29 abr. 2026.

GEUNIS, Lotte. **Parliamentary Monitoring Organizations: Partners in Parliamentary Oversight**. International IDEA. 2023. Disponível em: <<https://www.idea.int/publications/catalogue/html/parliamentary-monitoring-organizations-partners-parliamentary>>. Acesso em: 8 abr. 2026.

GIL, Antonio Carlos. **Como elaborar projetos de pesquisa**. 7. ed. São Paulo: Atlas, 2022.

GUPTA, Shailja; RANJAN, Rajesh; SINGH, Surya Narayan. **A Comprehensive Survey of Retrieval-Augmented Generation (RAG): Evolution, Current Landscape and Future Directions**. 2024. arXiv: [2410.12837](https://arxiv.org/abs/2410.12837). Disponível em: <<https://arxiv.org/abs/2410.12837>>. Acesso em: 8 abr. 2026.

HEVNER, Alan R.; MARCH, Salvatore T.; PARK, Jinsoo; RAM, Sudha. Design Science in Information Systems Research. **MIS Quarterly**, v. 28, n. 1, p. 75–105, 2004. DOI: [10.2307/25148625](https://doi.org/10.2307/25148625). Disponível em: <<https://aisel.aisnet.org/misq/vol28/iss1/6/>>. Acesso em: 29 abr. 2026.

INTER-PARLIAMENTARY UNION. **Use Cases for AI in Parliaments**. Geneva, 2024. Disponível em: <<https://www.ipu.org/file/20635/download>>. Acesso em: 8 abr. 2026.

JI, Ziwei; LEE, Nayeon; FRIESKE, Rita; YU, Tiezheng; SU, Dan; XU, Yan; ISHII, Etsuko; BANG, Ye Jin; MADOTTO, Andrea; FUNG, Pascale. Survey of Hallucination in Natural Language Generation. **ACM Computing Surveys**, v. 55, n. 12, p. 1–38, 2023. DOI: [10.1145/3571730](https://doi.org/10.1145/3571730). Disponível em: <<https://dl.acm.org/doi/10.1145/3571730>>. Acesso em: 25 jun. 2026.

KARPUKHIN, Vladimir; OĞUZ, Barlas; MIN, Sewon; LEWIS, Patrick; WU, Ledell; EDUNOV, Sergey; CHEN, Danqi; YIH, Wen-tau. Dense Passage Retrieval for Open-Domain Question Answering. In: PROCEEDINGS of the 2020 Conference on Empirical Methods in Natural Language Processing. Online: Association for Computational Linguistics, 2020. P. 6769–6781. DOI: [10.18653/v1/2020.emnlp-main.550](https://doi.org/10.18653/v1/2020.emnlp-main.550). Disponível em: <<https://aclanthology.org/2020.emnlp-main.550/>>. Acesso em: 25 jun. 2026.

KHALIQ, Mohammed Abdul; CHANG, Paul Yu-Chun; MA, Mingyang; PFLUGFELDER, Bernhard; MILETIĆ, Filip. RAGAR, Your Falsehood Radar: RAG-Augmented Reasoning for Political Fact-Checking Using Multimodal Large Language Models. In: PROCEEDINGS of the Seventh Fact Extraction and VERification Workshop (FEVER). Miami, Florida, USA: Association for Computational Linguistics, nov. 2024. P. 280–296. DOI: [10.18653/v1/2024.fever-1.29](https://doi.org/10.18653/v1/2024.fever-1.29). Disponível em: <<https://aclanthology.org/2024.fever-1.29/>>. Acesso em: 9 abr. 2026.

LAKATOS, Eva Maria; MARCONI, Marina de Andrade. **Fundamentos de metodologia científica**. 9. ed. São Paulo: Atlas, 2021.

LEWIS, Patrick; PEREZ, Ethan; PIKTUS, Aleksandra; PETRONI, Fabio; KARPUKHIN, Vladimir; GOYAL, Naman; KÜTTLER, Heinrich; LEWIS, Mike; YIH, Wen-tau; ROCKTÄSCHEL, Tim; RIEDEL, Sebastian; KIELA, Douwe.

Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In: ADVANCES in Neural Information Processing Systems. Curran Associates, Inc., 2020. v. 33, p. 9459–9474. Disponível em: <<https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>>. Acesso em: 29 abr. 2026.

LIANG, Percy; BOMMASANI, Rishi; LEE, Tony; TSIPRAS, Dimitris; SOYLU, Dilara; YASUNAGA, Michihiro; ZHANG, Yian; NARAYANAN, Deepak; WU, Yuhuai; KUMAR, Ananya; NEWMAN, Benjamin; YUAN, Binhang; YAN, Bobby; ZHANG, Ce; COSGROVE, Christian et al. Holistic Evaluation of Language Models. **Annals of the New York Academy of Sciences**, 2023. DOI: [10.1111/nyas.15007](https://doi.org/10.1111/nyas.15007). arXiv: [2211.09110](https://arxiv.org/abs/2211.09110). Disponível em: <<https://arxiv.org/abs/2211.09110>>. Acesso em: 25 jun. 2026.

LIU, Shuliang; LI, Xinze; LIU, Zhenghao; YAN, Yukun; YANG, Cheng; ZENG, Zheni; LIU, Zhiyuan; SUN, Maosong; YU, Ge. Judge as A Judge: Improving the Evaluation of Retrieval-Augmented Generation through the Judge-Consistency of Large Language Models. In: FINDINGS of the Association for Computational Linguistics: ACL 2025. Vienna, Austria: Association for Computational Linguistics, 2025. P. 5788–5807. DOI: [10.18653/v1/2025.findings-acl.301](https://doi.org/10.18653/v1/2025.findings-acl.301). Disponível em: <<https://aclanthology.org/2025.findings-acl.301/>>. Acesso em: 14 abr. 2026.

LIU, Yang; ITER, Dan; XU, Yichong; WANG, Shuohang; XU, Ruochen; ZHU, Chenguang. G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment. In: PROCEEDINGS of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023. P. 2511–2522. DOI: [10.18653/v1/2023.emnlp-main.153](https://doi.org/10.18653/v1/2023.emnlp-main.153). Disponível em: <<https://aclanthology.org/2023.emnlp-main.153/>>. Acesso em: 14 abr. 2026.

MANNING, Christopher D.; RAGHAVAN, Prabhakar; SCHÜTZE, Hinrich. **Introduction to Information Retrieval**. Cambridge: Cambridge University Press, 2008. Disponível em: <<https://nlp.stanford.edu/IR-book/>>. Acesso em: 18 mai. 2026.

MARTELLOTE VIOLA, Carla Maria; MARQUES FELIPE, Carla Beatriz; FARIAS SALES MARQUES, Luana. Inteligência Artificial na Organização do Conhecimento do Parlamento brasileiro: um estudo aplicado aos dados e às informações legislativas. **ISKO Brasil**, n. 8, 2025. Disponível em:

<<https://isko.org.br/ojs/index.php/iskobrasil/article/view/52>>. Acesso em: 9 abr. 2026.

MATOSHI, Veton; SINGH, Siddhartha; KUCERA, Jacqueline; MEYER, Philippe; GYGLI, Marcel. Transforming Digital Access in Parliament: Topic Modeling Meets Retrieval Augmented Generation. In: 2025 Eleventh International Conference on eDemocracy & eGovernment (ICEDEG). 2025. P. 123–130. DOI:

[10.1109/ICEDEG65568.2025.11081627](https://doi.org/10.1109/ICEDEG65568.2025.11081627). Disponível em:

<<https://doi.org/10.1109/ICEDEG65568.2025.11081627>>. Acesso em: 29 abr. 2026.

MINAEE, Shervin; MIKOLOV, Tomas; NIKZAD, Narjes; CHENAGHLU, Meysam; SOCHER, Richard; AMATRIAIN, Xavier; GAO, Jianfeng. **Large Language Models: A Survey**. 2024. arXiv: [2402.06196](https://arxiv.org/abs/2402.06196). Disponível em:

<<https://arxiv.org/abs/2402.06196>>. Acesso em: 8 abr. 2026.

MOSBACH, Sebastian; LAI, Jiawei; RUSTAGI, Kushagar; TRAN, Dan N.; KRAFT, Markus; BINDEREIF, Ewald; AZZAM, Mark. **Parliamentary debates in The World Avatar: A hybrid retrieval-augmented generation system**. Set. 2025. Disponível em:

<<https://como.ceb.cam.ac.uk/media/preprints/c4e-preprint-338.pdf>>. Acesso em: 29 abr. 2026.

NIE, Zhijie; FENG, Zhangchi; LI, Mingxin; ZHANG, Cunwang; ZHANG, Yanzhao; LONG, Dingkun; ZHANG, Richong. **When Text Embedding Meets Large Language Model: A Comprehensive Survey**. 2024. arXiv: [2412.09165](https://arxiv.org/abs/2412.09165). Disponível em: <<https://arxiv.org/abs/2412.09165>>. Acesso em: 8 abr. 2026.

OUYANG, Long; WU, Jeff; JIANG, Xu; ALMEIDA, Diogo; WAINWRIGHT, Carroll L.; MISHKIN, Pamela; ZHANG, Chong; AGARWAL, Sandhini; SLAMA, Katarina; RAY, Alex; SCHULMAN, John; HILTON, Jacob; KELTON, Fraser; MILLER, Luke; SIMENS, Maddie; ASKELL, Amanda; WELINDER, Peter; CHRISTIANO, Paul; LEIKE, Jan; LOWE, Ryan. Training Language Models to Follow Instructions with Human Feedback. In: ADVANCES in Neural Information Processing Systems. Curran Associates, Inc., 2022. v. 35, p. 27730–27744. Disponível em:

<https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html>. Acesso em: 25 jun. 2026.

PEFFERS, Ken; TUUNANEN, Tuure; ROTHENBERGER, Marcus A.; CHATTERJEE, Samir. A Design Science Research Methodology for Information Systems Research. **Journal of Management Information Systems**, v. 24, n. 3, p. 45–77, 2007. DOI: [10.2753/MIS0742-1222240302](https://doi.org/10.2753/MIS0742-1222240302). Disponível em:

<<https://doi.org/10.2753/MIS0742-1222240302>>. Acesso em: 29 abr. 2026.

PIPITONE, Nicholas; HOUIR ALAMI, Ghita. **LegalBench-RAG: A Benchmark for Retrieval-Augmented Generation in the Legal Domain**. 2024. DOI: [10.48550/arXiv.2408.10343](https://arxiv.org/abs/2408.10343). arXiv: [2408.10343](https://arxiv.org/abs/2408.10343). Disponível em: [〈https://arxiv.org/abs/2408.10343〉](https://arxiv.org/abs/2408.10343). Acesso em: 29 abr. 2026.

ROGIERS, Alexander; BUYL, Maarten; KANG, Bram; DE BIE, Tijl. KamerRaad: Enhancing Information Retrieval in Belgian National Politics Through Hierarchical Summarization and Conversational Interfaces. In: MACHINE Learning and Knowledge Discovery in Databases. Research Track and Demo Track (ECML PKDD 2024). Cham: Springer, 2024. v. 14948. (Lecture Notes in Computer Science), p. 503–519. DOI: [10.1007/978-3-031-70371-3_30](https://arxiv.org/abs/2404.17597). Disponível em: [〈https://arxiv.org/abs/2404.17597〉](https://arxiv.org/abs/2404.17597). Acesso em: 29 abr. 2026.

SAAD-FALCON, Jon; KHATTAB, Omar; POTTS, Christopher; ZAHARIA, Matei. ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems. In: PROCEEDINGS of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). Mexico City, Mexico: Association for Computational Linguistics, 2024. P. 338–354. DOI: [10.18653/v1/2024.naacl-long.20](https://aclanthology.org/2024.naacl-long.20). Disponível em: [〈https://aclanthology.org/2024.naacl-long.20/〉](https://aclanthology.org/2024.naacl-long.20/). Acesso em: 21 abr. 2026.

SKUBIC, Jure; FIŠER, Darja. Parliamentary Discourse Research in Political Science: Literature Review. In: PROCEEDINGS of the IV Workshop on Creating, Analysing, and Increasing Accessibility of Parliamentary Corpora (ParlaCLARIN) @ LREC-COLING 2024. Torino, Italia: ELRA e ICCL, mai. 2024. P. 1–11. Disponível em: [〈https://aclanthology.org/2024.parlaclarin-1.1/〉](https://aclanthology.org/2024.parlaclarin-1.1/). Acesso em: 8 abr. 2026.

THAKUR, Nandan; REIMERS, Nils; RÜCKLÉ, Andreas; SRIVASTAVA, Abhishek; GUREVYCH, Iryna. BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models. In: PROCEEDINGS of the Neural Information Processing Systems Track on Datasets and Benchmarks. 2021. v. 1. Disponível em: [〈https://openreview.net/forum?id=wCu6T5xFjeJ〉](https://openreview.net/forum?id=wCu6T5xFjeJ). Acesso em: 18 mai. 2026.

VASWANI, Ashish; SHAZEER, Noam; PARMAR, Niki; USZKOREIT, Jakob; JONES, Llion; GOMEZ, Aidan N.; KAISER, Lukasz; POLOSUKHIN, Illia. **Attention Is All You Need**. 2017. arXiv: [1706.03762](https://arxiv.org/abs/1706.03762). Disponível em: [〈https://arxiv.org/abs/1706.03762〉](https://arxiv.org/abs/1706.03762). Acesso em: 8 abr. 2026.

WESTMINSTER FOUNDATION FOR DEMOCRACY. **Guidelines for AI in Parliaments**. London, 2023. Disponível em: [〈https://www.agora-parl.org/sites/default/files/agora-documents/English%20-%20WFD%20AI%20Guidelines%20for%20Parliaments.pdf〉](https://www.agora-parl.org/sites/default/files/agora-documents/English%20-%20WFD%20AI%20Guidelines%20for%20Parliaments.pdf). Acesso em: 8 abr. 2026.

ZHAO, Wayne Xin; ZHOU, Kun; LI, Junyi; TANG, Tianyi; WANG, Xiaolei; HOU, Yupeng; MIN, Yingqian; ZHANG, Beichen; ZHANG, Junjie; DONG, Zican; DU, Yifan; YANG, Chen et al. **A Survey of Large Language Models**. 2023. arXiv: [2303.18223](https://arxiv.org/abs/2303.18223). Disponível em: <<https://arxiv.org/abs/2303.18223>>. Acesso em: 25 jun. 2026.

ZHU, Kunlun; LUO, Yifan; XU, Dingling; YAN, Yukun; LIU, Zhenghao; YU, Shi; WANG, Ruobing; WANG, Shuo; LI, Yishan; ZHANG, Nan; HAN, Xu; LIU, Zhiyuan; SUN, Maosong. RAGEval: Scenario Specific RAG Evaluation Dataset Generation Framework. In: PROCEEDINGS of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Vienna, Austria: Association for Computational Linguistics, 2025. P. 8520–8544. DOI: [10.18653/v1/2025.acl-long.418](https://aclanthology.org/2025.acl-long.418). Disponível em: <<https://aclanthology.org/2025.acl-long.418/>>. Acesso em: 14 abr. 2026.